ФИНАЛЬНАЯ ЗАЩИТА

Cloud Digest

Из потока публикаций — в понятные приоритеты редактора



Рабочий прототип · Python + Streamlit · версия для демонстрации

Важен не поток сообщений, а сюжет

Brand Analytics уже собирает публикации. Наша задача — помочь редактору быстрее выделить главное.

Повторы

Одна новость появляется в разных СМИ, каналах и пересказах. Отдельные записи отвлекают от сюжета.

Поздние репосты

Крупное издание может опубликовать новость позже, но существенно изменить её влияние.

Очередь редактора

Важные и спорные случаи нужно показать первыми и объяснить причину выбора.

Cloud Digest — не замена Brand Analytics. Это дополнительный слой группировки, приоритизации и редакторской проверки.

Что делает Cloud Digest

Объединяет публикации об одном событии, оценивает сюжет и показывает основания для решения.

Ранняя новость

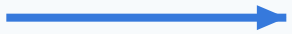
Отдельная публикация · 0 баллов

Поздний репост

Отдельная публикация · 30 баллов

Пересказ

Отдельная публикация · 0 баллов



ОДИН СЮЖЕТ

Главный источник, Story Score и история распространения

Редактор видит причину приоритета

На синтетическом примере: старая карточка **0 баллов** → новый **Story Score 34**. Это демонстрация функций, не метрика точности модели.

Что принимает и что выдаёт

Система работает с выгрузкой BA или совместимым датасетом без обязательного API.

Вход: JSON / CSV

- Текст, дата и URL
- Название и тип источника
- Аудитория и просмотры
- Тональность и метки BA

Обработка

- Очистка и бренд
- Кластеры / embeddings
- Оценка публикаций и сюжетов
- Карточки

Результат

- Дайджест JSON / TXT / ZIP
- Лента и главная публикация
- Алерты и очередь проверки
- Экспорт редакторских решений

Связь с BA: локальные выгрузки; двусторонний API пока не реализован

Архитектура: пять простых блоков

Каждый блок — отдельный Python-модуль. Новые алгоритмы можно заменять независимо.

01

Загрузка

validation.py
preprocessing.py

02

Сюжеты

embeddings.py
clustering.py

03

Оценка

scoring.py
story_scoring.py

04

Дайджест

digest.py
story_view.py

05

Редактор

Streamlit
ui/app.py

Вычисления выполняет **Cloud Digest Engine**. Панель лишь показывает результат и сохраняет правки; формулы скоринга не дублируются в интерфейсе.

Что уже реализовано

Восемь этапов собраны в четыре функциональных блока.

01–02	**Основа** Рефакторинг; проверка входных данных; нормализация
03–04	**Смысловая обработка** Embeddings, пороги сходства, проверка событий
05–07	**Приоритеты и интерфейс** Publication Score, Story Score, дайджест и панель
08	**Проверка качества** Golden set, тесты, инструменты сравнения и калибровки

Реализовано в коде ≠ качество подтверждено экспериментом

Что обработано на реальной выгрузке

31 августа 2026 года · показатели детерминированного baseline-v1.

510
сообщений во всей выгрузке

169
сообщений за 31 августа

154
кандидата с упоминанием

30
карточек в дайджесте

Baseline: **104 кластера**, **50 повторов**, **16 на проверку**. Повторный аудит Golden set: **169 записей**, **27 изменений релевантности**, **60 спорных**.

Повторный аудит Golden set

Разметка уточнена, показатели пересчитаны. Качество semantic пока не измерено.

Метрика	Dev · 127	Test · 27
Pairwise Precision	96,58%	95,24%
Pairwise Recall	1,61%	33,90%
Pairwise F1	**3,17%**	**50,00%**
B-cubed F1	15,79%	75,38%
Story Recall@30	33,33%	66,67%
Story NDCG@30*	86,09%	78,37%

Статус: DRAFT. Повторно размечено 169 сообщений; 27 relevances изменены; 60 требуют проверки. Измерены baseline-кластеры и Story Score **без embeddings**. *NDCG — только по размеченным карточкам.

Источник: Golden Set READUIT + evaluation.py, baseline; 07.11.2026

Три состояния панели

Демонстрационные публикации вымышлены; все три сценария проверены через CLI.

Обычный день

2 сюжета

Поздняя крупная публикация становится главной. **Story Score 34**.

Кризисный день

АЛЕРТ · 88/100

Система выделяет учебный инцидент и открывает редакторскую проверку.

Пустой день

0 сюжетов

Нет релевантных сообщений. Панель показывает понятное пустое состояние.

Запуск: **RUN_DEMO_WINDOWS.bat** → **RUN_DASHBOARD_WINDOWS.bat** → выбрать готовый digest.

Источники: demo/scenarios/ready/*; smoke test без embeddings, не проверка accuracy

Как человек использует систему

Cloud Digest не заменяет решение редактора, а делает его быстрее и прозрачнее.

Лента сюжетов

34 · Отчётность

32 · Вебинар

— · Фильтры

Карточка выбранного сюжета

Главный источник, история репостов, факторы Story Score, причины отправки в очередь проверки.

Почему такой приоритет

История сюжета

Правка редактора

Правки сохраняются отдельно. **Автоматический пересчёт после правки и запись в BA через API пока не реализованы.**

Экономия времени — главная гипотеза

Сценарная модель, не подтверждённый замер работы редактора.

Без Cloud Digest

1,50 мин

на одну публикацию
106 250 ₽/мес. редакторской работы

→

С Cloud Digest

0,65 мин

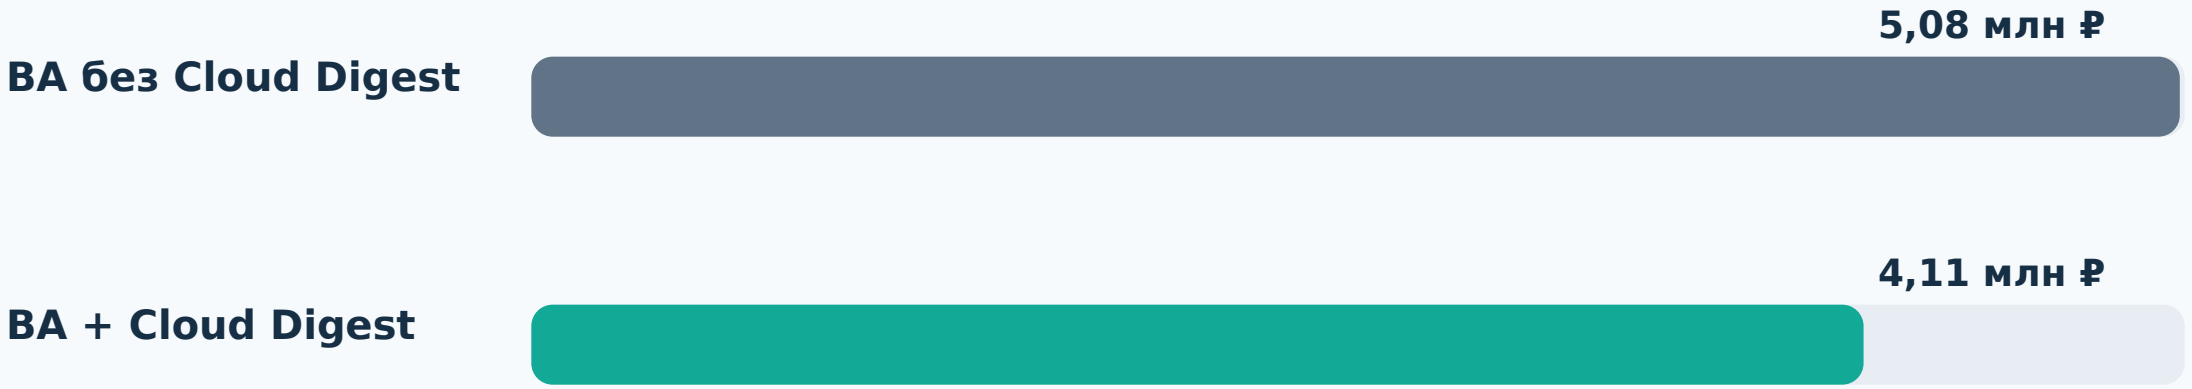
на одну публикацию
46 042 ₽/мес. редакторской работы

Допущения: **5 000 публикаций/мес.** × **850 ₽/час**; дополнительная инфраструктура и поддержка — **22 000 ₽/мес.**

Источник: «Экономическое обоснование Cloud Digest»; время 1,50/0,65 мин не измерено

Сценарий: TCO за 36 месяцев

Сравниваем BA с существующим редакторским процессом и BA + Cloud Digest.



975 500 ₽

потенциальное снижение TCO (19,2%). Разовая интеграция — 400 тыс. ₽; окупаемость — ~10,5 мес.

BA остаётся в обеих схемах (модель: 35 тыс. ₽/мес.). Экономия исчезает, если фактическое ускорение работы недостаточно или потребуется дорогой API.

Что осталось до полноценного MVP

Следующий шаг — подтвердить полезность на редакторском пилоте, а не добавлять функции ради функций.

1. **Подтвердить Golden set**
   169 предварительных меток, 60 спорных; нужна независимая проверка.

2. **Проверить semantic vs baseline**
   Реальная MiniLM, одни данные, фиксированные пороги, метрики F1/NDCG.

3. **Замерить работу редактора**
   Время, пропущенные сюжеты, частота исправлений, TCO.

4. **Довести интеграцию**
   Пересчёт после правок, API BA по согласованному контракту.

ФИНАЛ

Итог: что уже доказано

Cloud Digest — работающий модуль, который помогает превращать публикации в понятную очередь сюжетов.

Работает сейчас: обработка выгрузок, Story Score, панель и три сценария.
Golden set обновлён: 169 предварительных меток; baseline пересчитан. **Для финала:** подтвердить разметку и измерить semantic.

Основания и источники

Код и данные:	Cloud Digest, репозиторий и результаты 31.08.2026
Метрики:	Cloud_Digest_Golden_Set_Metrics_DRAFT.docx (RE-AUDIT)
Экономика:	Cloud_Digest_ekonomicheskoe_obosnovanie_TCO.docx
Тариф BA:	brandanalytics.ru/en_US/price/ (35 000 ₽/мес.; публичный ориентир)
Серверы:	timeweb.cloud/services/cloud-servers (конфигурации и прайс)